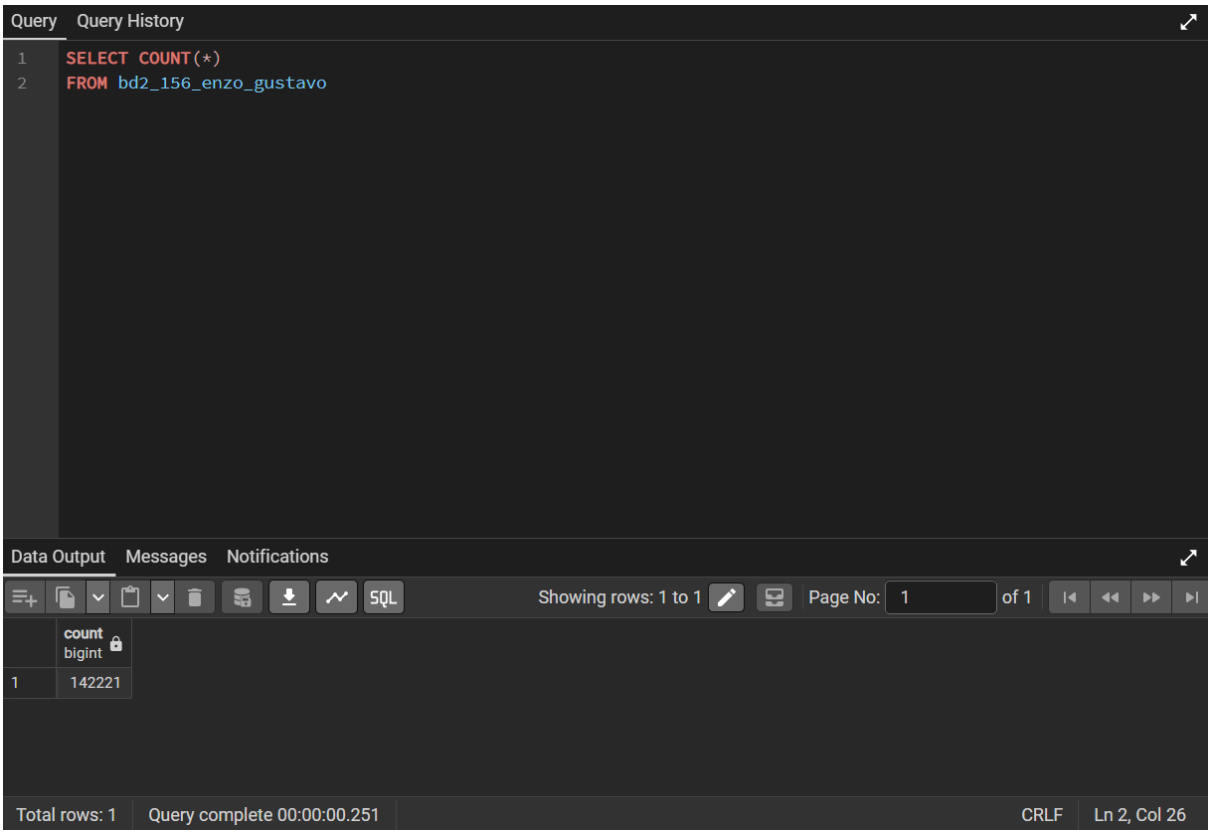
Enzo Nakamura Kira, Gustavo H. Santos

O banco utilizado foi o 156 na faixa de anos de 2017 e 2018, inserido na tabela bd2_156_enzo_gustavo

2) Faça a inserção dos dados da sua tabela. Ela obrigatoriamente deve estar no banco de Dados Postgiscwb. Cole abaixo o resultado do comando select count(*) da sua tabela.



3) Escreva um parágrafo sobre a qualidade dos dados: quantos arquivos foram utilizados, qual o formato, se havia muito null, se estavam no formato do dicionário de dados, se o cabeçário possuía palavras em inglês, português ou abreviações, se haviam muitos dados duplicados, se houveram desafios para a inserção, etc.

Usamos 24 arquivos .csv. Encontramos tipos null, principalmente nos campos de data, como nascimento, que precisaram ser tratados para serem inseridos na tabela. Além disso, tivemos que verificar o tamanho máximo dos vários campos, para definir o tamanho máximo dos campos de texto. Todo o cabeçalho era em português. Tivemos também que limpar os textos em branco ao redor das strings. Fizemos tudo em Python. Eram 238,613 linhas de dados, das quais 92,519 eram duplicatas, e ficamos no final com 146,094 linhas de dados. São 67,365 linhas de dados sem chave primária, pois a informação do número da solicitação está nulo.

4) Indicar como foi o processo de inserção (dbvisualizer, código python, etc.) e o tempo médio de inserção. Relate qualquer outro problema enfrentado. Utilize o

máximo de colunas e dados possíveis. Escreva um parágrafo sobre a qualidade dos dados: quantos arquivos foram utilizados, qual o formato, se havia muito null, se estavam no formato do dicionário de dados, se o cabeçário possuía palavras em inglês, português ou abreviações, se haviam muitos dados duplicados, se houveram desafios para a inserção, etc.

Usamos Python. O processamento levou 2min para rodar no python. A inserção levou cerca de 3 min. Como limpamos as duplicatas no python, fizemos a inserção sem a primary key.

Tendo verificado duplicatas e campos com NULL a coluna SOLICITACAO foi a ideal para ser a primary key da tabela