Enzo Nakamura Kira, Gustavo H. Santos

O banco utilizado foi o 156 na faixa de anos de 2017 e 2018, inserido na tabela bd2_156_enzo_gustavo

1.0) Listar quais as colunas de texto livre e colunas estruturadas .

Nós olhamos as colunas “DESCRICAO”, “OBSERVACAO”, “MENSAGEM_RESPOSTA“ e “RESPOSTA_FINAL” já que estas são colunas de texto livre que podem conter informações pessoais. O restante são colunas com uma estrutura já melhor definida

1.1) Identificar/classificar os campos que podem gerar problemas de anonimização (nome, telefone, e-mail, CPF, endereço). Ilustre a quantidade de tuplas e faça um relatório (porcentagem, exemplos, etc.) de tuplas que possuem informações confidenciais (como nome, telefone, e-mail, CPF, RG, endereço). Ilustre os SQLs/códigos utilizados, o tempo requerido. Verifique se outra informação confidencial está presente.

Tuplas com data de nascimento:

Como os dados do 156 de 2017-2018 têm uma coluna de data de nascimento, nós notamos que apenas 2451 das 146,094 tuplas têm o campo data de nascimento como nulo. Ou seja, 98,3% dos dados contêm a data de nascimento do usuário;

Tuplas de telefone:

Usamos o seguinte regex para encontrar a presença de números de telefone:

```
phone_regex                                                                    =
r'(?:\b(?:\(?0?[1-9]{2}\)?\s*)?(?:9\s*)?[2-9]\d{3}[-\s]?\d{4}\b)'
```

Com ele, olhamos as colunas de e em 2,6s encontramos 4371 tuplas com números de telefone;

Tuplas de e-mail:

Usamos o seguinte regex para encontrar a presença de e-mail:

```
email_regex = r'(?i)\b[A-Z0-9._%+-]+@[A-Z0-9.-]+\.[A-Z]{2,}\b'
```

Com ele, olhando as colunas, e em 2,2s encontramos 162 tuplas com números de telefone; Em várias delas, o e-mail é da própria prefeitura, ou seja, o e-mail que a prefeitura enviou para o usuário entrar em contato.

Tuplas de CPF:

Usamos o seguinte regex para encontrar a presença de CPF:

```
cpf_regex = r'(?:\b\d{3}\.\d{3}\.\d{3}-\d{2}\b|\b\d{11}\b)'
```

Com ele encontramos, em 1,7 s, 39 tuplas com CPF.

Tuplas de RG:

Usamos o seguinte regex para encontrar a presença de RG:

```
rg_regex =
r'(?i)(?:\b(?:RG|R\.G\.)\s*[:=]?\s*[0-9.]{7,12}-?[0-9Xx]\b|\b\d{1,2}\.\
d{3}\.\d{3}-[0-9Xx]\b)'
```

Com ele encontramos, em 1,5 s, 11 tuplas com RG.

Tuplas com endereço:

No caso do endereço, existe uma coluna com o logradouro LOGRADOURO_ASS e apenas uma das tuplas não contém esse dado; Dessas, 121.414 (83% do total) incluem o logradouro/número da rua. Usamos o seguinte código Python para isso:

```
addresses = df['LOGRADOURO_ASS'].dropna()

# 2. Split the address string by the comma (creates a dataframe with 2
columns: street and number)
address_parts = addresses.str.split(',', expand=True)

# 3. Ensure the split resulted in at least two columns (street and
number)
if address_parts.shape[1] >= 2:
    # Check that the street part is not empty
    has_street = address_parts[0].str.strip().str.len() > 0
```

```
    # Check that the number part exists, is composed of digits, and is
not "0"
    has_number = (
        address_parts[1].notna() &
        address_parts[1].str.strip().str.isnumeric() &
        (address_parts[1].str.strip() != '0')
    )

    # Calculate the total where both conditions are true
    valid_addresses_count = (has_street & has_number).sum()

     print(f"Total addresses with both a street and a valid number:
{valid_addresses_count}")
else:
    print("No addresses found with the 'Street, Number' format.")
```

Tuplas com Cartão de Crédito:

No caso do cartão de crédito, encontramos um único caso (usando regex e Python), validado de número de cartão de crédito presente, na solicitação 6739058, com o número do cartão completo no campo OBSERVACAO;

Tuplas com conta bancária:

No caso da conta bancária, encontramos um único caso (usando regex e Python), validado de número de conta bancária presente, na solicitação 6661328, com o número do cartão completo no campo OBSERVACAO; Nele está presente a agência e o número da conta do usuario;

Tuplas com PIS/PASEP/NIP/Título de Eleitor:

Usamos regexes para esses 4 tipos de valores, com validação onde aplicável, e não encontramos nenhum deles nos dados estudados;

Tuplas com nome:

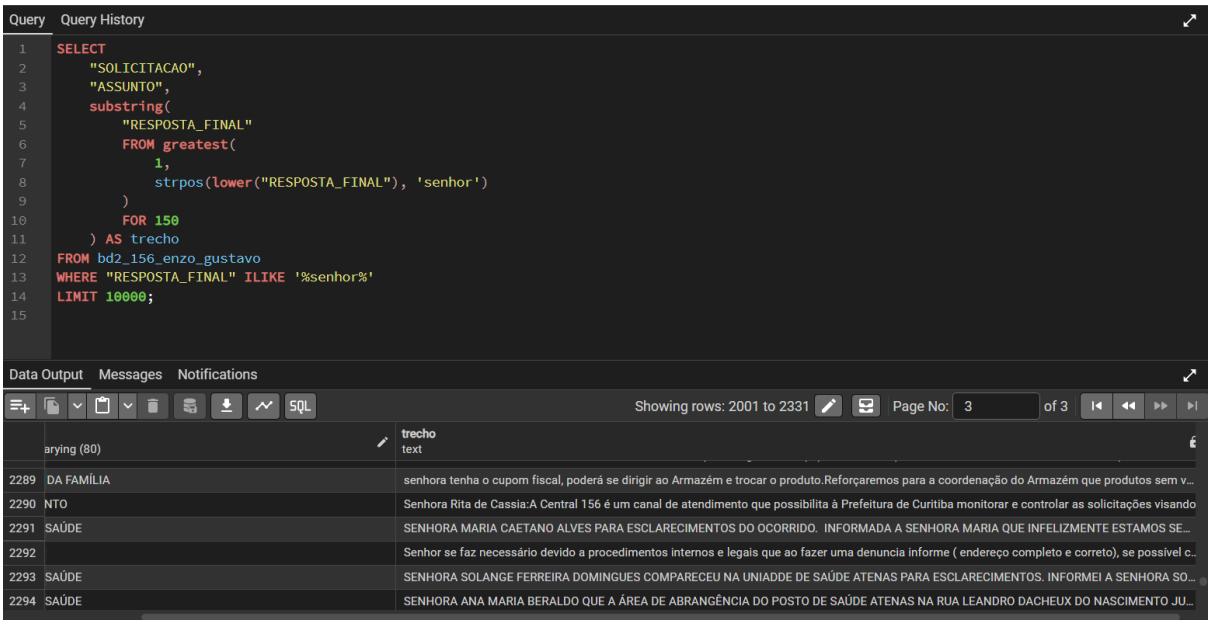
Não conseguimos achar um método eficiente para encontrar nomes, testamos regex buscando por termos como *sr.*, mas isso captura muitos falsos positivos:

```
name_trigger_regex                                                    =
r'(?i)\b(?:nome|sr\.?|sra\.?|senhor|senhora|cidadão)[:\s]+([A-ZÀ-Ÿa-zà-
ÿ]+(?:\s+[A-ZÀ-Ÿa-zà-ÿ]+){1,5})\b'
```

Usamos também o a biblioteca spacy de NLP (Natural Language Processing), e depois de 5minutos de execução, ainda notamos muitos falsos positivos:

```
nlp = spacy.load("pt_core_news_sm", disable=["parser", "attribute_ruler", "lemmatizer"])
```

Por SQL foi possível encontrar 2331 resultados com nomes divulgados, porém a precisão da identificação é insatisfatória e incerta, causando problemas discutidos mais a frente



1.2) Escolha uma técnica open-source (mascaramento, generalização, pseudonimização, hash criptográfico com salt, tokenização, k-anonimato) para retirar a anonimização. Ilustre o processo para fazer esta anonimização em cada campo.

As técnicas são melhor aplicadas utilizando Python, já que possibilita maior flexibilidade na identificação dessas tuplas e anonimização delas.

Tuplas com data de nascimento:

Nesse caso, seria uma possibilidade excluir a coluna inteira ou anonimizar substituindo dia ou mês por caracteres como X ou *. A coluna DATA_NASC contém essas informações

Tuplas com telefone, e-mail, CPF, RG, Cartão de Crédito, Conta bancária:

Utilizando o mesmo método para encontrar as tuplas basta censurar parte ou as informações completamente da mesma forma que a data de nascimento.

Tuplas com endereço:

Como o endereço é uma informação relevante para o atendimento das reclamações/solicitações, o método utilizado para anonimizar essa coluna é alterar os valores dos números das residências. Isso mantém a identificação da localização sem divulgar a residência exata de cidadãos. A coluna LOGRADOURO_ASS contém essas informações: (Presente na figura abaixo)

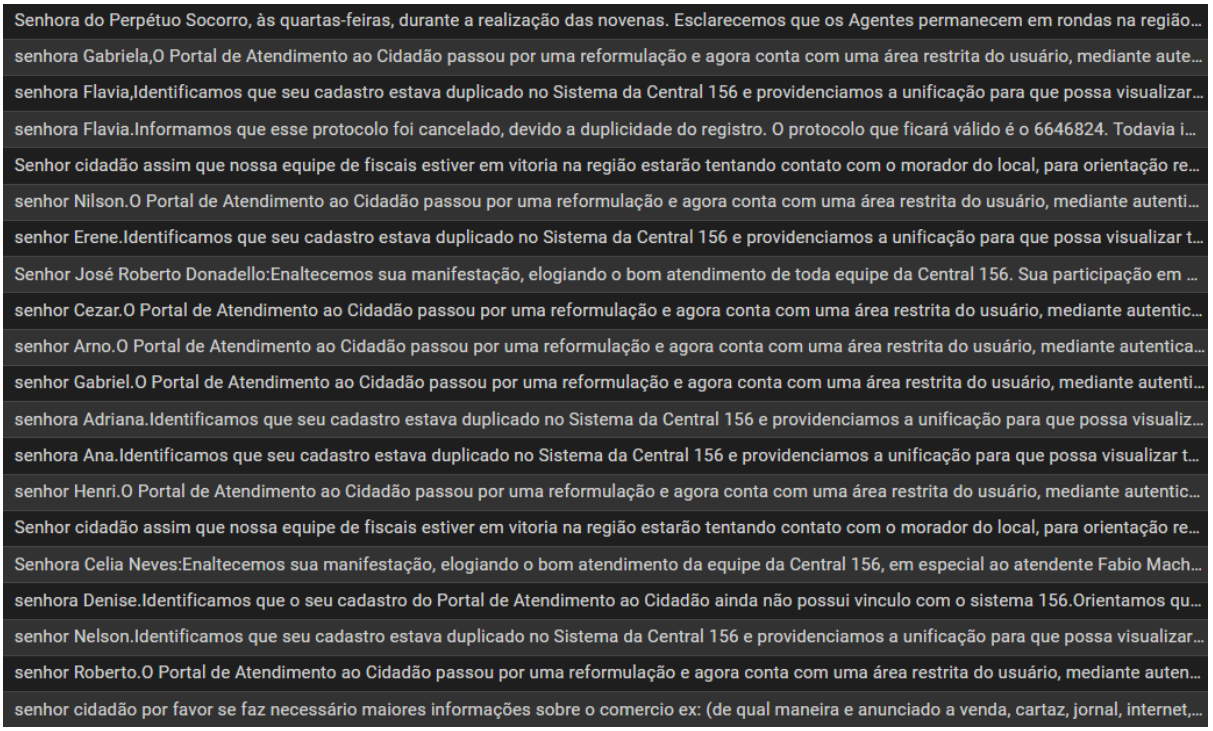
	SOLICITACAO	TIPO	ORGAO	DATA	HORARIO	ASSUNTO	SUBDIVISAO	DESCRICAO	LOGRADOURO_ASS	BAIRRO_ASS	...	MEIO_RESPOSTA	OBSERVACAO	SE
0	6714627	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	20/12/2016	11:07:08	ABORDAGEM SOCIAL DE RUA - ADULTO	DORMINDO/CAÍDAS NA RUA	ABORDAGEM SOCIAL DE RUA - ADULTO - DORMINDO/CA...	DESEMBARGADOR MOTTA, 3548	MERCES	...	NENHUM	NaN	
1	6638498	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	13/10/2016	18:26:03	ABORDAGEM SOCIAL DE RUA - ADULTO	OPERAÇÃO INVERNO	ABORDAGEM SOCIAL DE RUA - ADULTO - OPERAÇÃO IN...	DESEMBARGADOR MOTTA, 0	AGUA VERDE	...	EMAIL	NÃO SOUBE INFORMAR NUMERAÇÃO PREDIAL.	
2	6676499	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	16/11/2016	16:21:54	TRÂNSITO	FISCALIZAÇÃO IMEDIATA	TRÂNSITO - FISCALIZAÇÃO IMEDIATA	DESEMBARGADOR MOTTA, 0	AGUA VERDE	...	NENHUM	NÃO SOUBE INFORMAR NUMERAÇÃO PREDIAL.	
3	6648756	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	21/10/2016	18:59:41	ABORDAGEM SOCIAL DE RUA - ADULTO	PESSOAS/FAMÍLIAS EM DESABRIGO NA RUA	ABORDAGEM SOCIAL DE RUA - ADULTO - PESSOAS/FAM...	VISCONDE DE GUARAPUAVA, 2684	CENTRO	...	NENHUM	NaN	
4	6659329	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	31/10/2016	22:59:42	ABORDAGEM SOCIAL DE RUA - ADULTO	PESSOAS/FAMÍLIAS EM DESABRIGO NA RUA	ABORDAGEM SOCIAL DE RUA - ADULTO - PESSOAS/FAM...	VISCONDE DE GUARAPUAVA, 0	CENTRO	...	NENHUM	NÃO SOUBE INFORMAR A NUMERAÇÃO PREDIAL, MAS ES...	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	
142216	7556281	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	12/11/2018	10:35:34	PASSEIO	OBSTRUÇÃO DO PASSEIO	SOLICITA FISCALIZAÇÃO QUANTO A OBSTRUÇÃO DE CA...	JOSÉ RAKSA, 406	CAPAO RASO	...	EMAIL	NaN	
142217	7556228	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	12/11/2018	10:17:59	PAVIMENTAÇÃO	IMPLANTAÇÃO	SOLICITA IMPLANTAÇÃO DE ASFALTO. SEGUE DESCRIÇ...	BÔRTOLO GUSSO, 904	CAPAO RASO	...	EMAIL	NaN	
142218	7556463	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	12/11/2018	11:32:58	PAVIMENTAÇÃO	IMPLANTAÇÃO	SOLICITA IMPLANTAÇÃO DE ASFALTO. SEGUE DESCRIÇ...	IRMÃ FLÁVIA BORLET, 818	BOQUEIRAO	...	EMAIL	NaN	
142219	7558128	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	13/11/2018	09:50:46	ÔNIBUS	SUGESTÃO DE MELHORIA	SOLICITA VERIFICAÇÃO COM RELAÇÃO A SITUAÇÃO RE...	ANDERSON JULIANO ROSA NASCIMENTO, 26	CAMPO DE SANTANA	...	EMAIL	NÃO INFORMOU PONTO DE REFERÊNCIA, IDENTIFICAÇ...	
142220	7554281	SOLICITAÇÃO	INSTITUTO DAS CIDADES INTELIGENTES	09/11/2018	15:18:12	TRÂNSITO	FISCALIZAÇÃO DE ESTACIONAMENTO IRREGULAR	SOLICITA FISCALIZAÇÃO DE TRÂNSITO.	SÃO SEBASTIÃO, 298	AHU	...	NENHUM	DO OUTRO LADO DA RUA.	

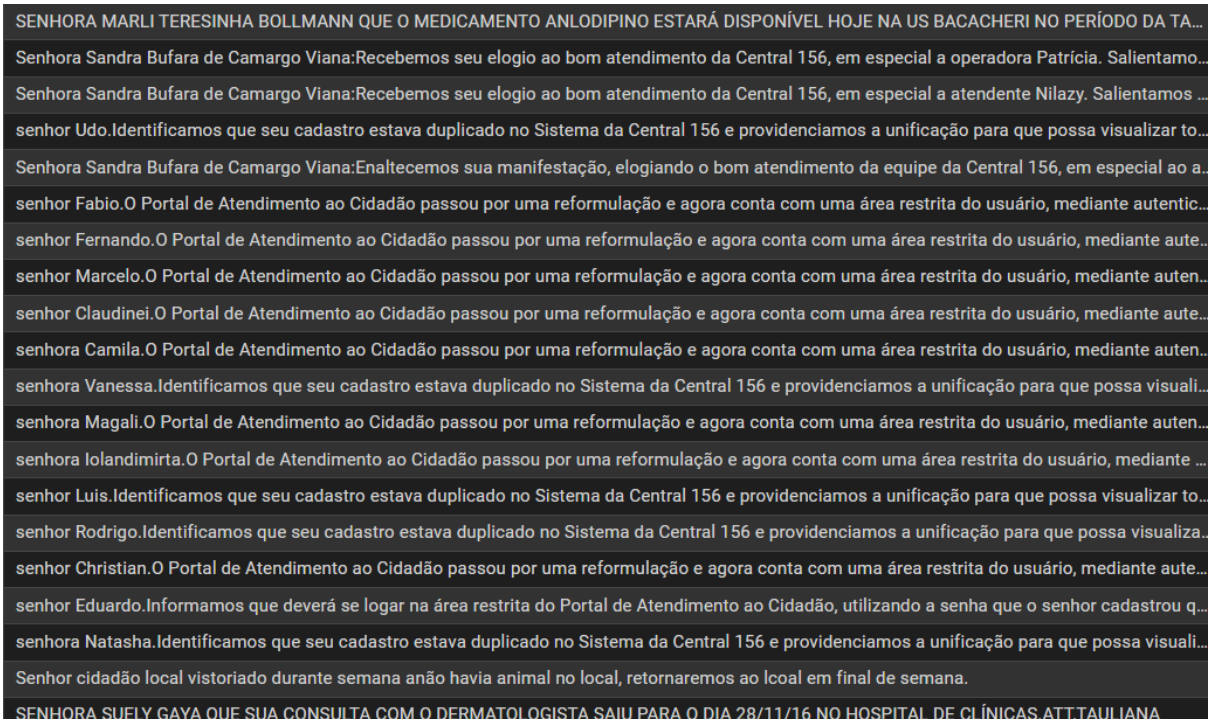
Tuplas com nome:

O processo de anonimização de nomes apresenta as maiores dificuldades, sem a utilização de modelos de inteligência artificial ou bancos de dados externos de nomes a identificação de um nome é praticamente impossível, já que não existem métodos confiáveis para realizar a distinção, dificultado ainda mais por nomes de ruas originados por nomes de pessoas.

O processo a ser feito, considerando tais limitações, seria buscar as tuplas usando pronomes de tratamento comuns, como senhor, senhora, doutor, doutora, entre outros, e censurar algum número de palavras à frente do pronome para tentar ocultar parte do nome das pessoas.

Esse método é incapaz de anonimizar completamente essa informação e pode resultar na perda de palavras do texto original, apesar disso é o melhor que pôde ser feito.





Esses exemplos demonstram a dificuldade de solucionar o problema, em alguns casos é divulgado apenas o primeiro nome, outros o nome inteiro, outros usam senhor cidadão, outros só senhor e até nomes de igrejas que contém o vocativo senhora. Isso evidencia a necessidade de algum identificador de nomes para anonimizar esses dados com certeza, contudo é um processo extremamente custoso.

1.3) Listar todos os problemas de Padronização existentes, quantificar e exemplificar (Inconsistência de maiúsculas/minúsculas, espaços extras, acentuação, formatação de documentos, valores equivalentes representados de formas diferentes, formatos de data e unidades variados, representações distintas de nulos, problemas de encoding e ordem inconsistente de campos compostos, entre outros).

Problemas de minúsculas/maiúsculas

Existem vários problemas de padronização existentes, como diferentes formas de escrever o nome de bairro:

Exemplos em BAIRRO_CIDADAO:

chave	representações
sao gabriel	[SAO GABRIEL, SÃO GABRIEL, SãO GABRIEL]
sao sebastiao	[SAO SEBASTIAO, SÃO SEBASTIAO, SÃO SEBASTIÃO]
nacoes ii	[NACOES II, NAÇOES II, NAÇÕES II]
almirante tamandare	[ALMIRANTE TAMANDARE, ALMIRANTE TAMANDARÉ]
centro	[CENTRO, centro]
campo pequeno	[CAMPO PEQUENO, CAMPO PEQUENO]
alto boqueirao	[ALTO BOQUEIRAO, ALTO BOQUEIRÃO]
colonia rio grande	[COLONIA RIO GRANDE, COLÔNIA RIO GRANDE]

A tabela a seguir descreve todas as colunas afetadas por valores que são similares, exceto por variações de maiúscula/minúscula e acento:

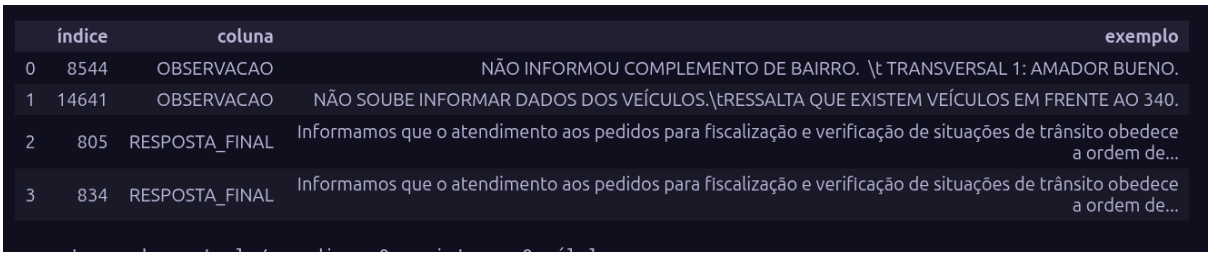
	coluna	grupos	registros_afetados
5	RESPOSTA_FINAL	383	36541
4	BAIRRO_CIDADAO	36	17668
3	OBSERVACAO	278	14948
2	LOGRADOURO_ASS	1300	9620
6	MENSAGEM_RESPOSTA	45	9160
1	DESCRICAO	6	1150
0	ASSUNTO	1	5

Problemas de espaço no início/fim

15.129 tuplas apresentaram esse problema nos campos de texto analisados;

Problemas de códigos de texto (ex. \t)

927 tuplas apresentaram esse problema:



	índice	coluna	exemplo
0	8544	OBSERVACAO	NÃO INFORMOU COMPLEMENTO DE BAIRRO. \t TRANSVERSAL 1: AMADOR BUENO.
1	14641	OBSERVACAO	NÃO SOUBE INFORMAR DADOS DOS VEÍCULOS.\tRESSALTA QUE EXISTEM VEÍCULOS EM FRENTE AO 340.
2	805	RESPOSTA_FINAL	Informamos que o atendimento aos pedidos para fiscalização e verificação de situações de trânsito obedece a ordem de...
3	834	RESPOSTA_FINAL	Informamos que o atendimento aos pedidos para fiscalização e verificação de situações de trânsito obedece a ordem de...

Problemas de formatação de data

Todas as tuplas/colunas usam o mesmo formato

Problemas de nulo

Na tabela, todos os nulos são nulos verdadeiros, ou seja, nenhum campo como “NULL” apareceu.