Descrição e preparação dos dados do serviço 156 de Curitiba nos anos de 2017 e 2018

Enzo Nakamura Kira[1], **Gustavo Henrique Bruno dos Santos**[1]

[1]Universidade Tecnológica Federal do Paraná (UTFPR)
Curitiba – PR – Brasil

Abstract. *This paper summarizes the preparation of Curitiba's 156 service data from 2017 and 2018. We used 24 CSV files and Python to handle missing values, remove duplicates and load the data into Postgiscwb. We describe the main documented attributes, data quality issues, personal information found in the records and the subsequent addition of geographic coordinates.*

Resumo. *Este artigo resume a preparação dos dados do serviço 156 de Curitiba nos anos de 2017 e 2018. Usamos 24 arquivos CSV e Python para tratar valores nulos, remover duplicatas e inserir os dados no Postgiscwb. Apresentamos os principais atributos documentados, os problemas de qualidade, as informações pessoais encontradas nos registros e a inclusão posterior de coordenadas geográficas.*

1. Introdução

O banco utilizado foi o 156 na faixa de anos de 2017 e 2018, inserido na tabela `bd2_156_enzo_gustavo` do Postgiscwb. Neste artigo, resumimos a preparação dos registros de solicitações e atendimentos, os problemas encontrados e a inclusão de coordenadas geográficas.

2. Descrição dos dados e inserção

Usamos 24 arquivos `.csv`, com cabeçalhos em português. Eram 238.613 linhas de dados, das quais 92.519 eram duplicatas. Após a limpeza em Python, ficamos com 146.094 registros. Já o `SELECT COUNT(*)` da Tarefa 02 retornou 142.221 tuplas, total também registrado na atividade de georreferenciamento. Os relatórios não explicam essa diferença de 3.873 registros.

Encontramos valores nulos, principalmente nos campos de data, que precisaram ser tratados. Tivemos também que verificar o tamanho máximo dos campos de texto e limpar os espaços ao redor das strings. Fizemos tudo em Python: o processamento levou cerca de dois minutos e a inserção, três minutos. Inserimos os dados sem chave primária, pois 67.365 registros tinham `SOLICITACAO` nula, impedindo seu uso direto como chave.

A Tabela 1 apresenta os principais atributos documentados nas atividades. A natureza indicada descreve o conteúdo dos campos, pois os relatórios não apresentam o esquema SQL completo.

3. Qualidade dos dados e informações pessoais

Encontramos variações de maiúsculas, minúsculas e acentuação, por exemplo na escrita dos bairros. Foram relatadas 15.129 tuplas com espaços no início ou no fim dos textos e

Tabela 1. Principais atributos documentados nas atividades.

Atributo	Natureza	Descrição
SOLICITACAO	Identificador	Número da solicitação.
DATA_NASC	Data	Data de nascimento do usuário.
LOGRADOURO_ASS	Texto	Logradouro; pode incluir número do imóvel.
DESCRICAO, OBSERVACAO	Texto livre	Descrição e observações da solicitação.
MENSAGEM_RESPOSTA, RESPOSTA_FINAL	Texto livre	Respostas do atendimento.
geom	Geometria	Ponto adicionado com SRID 4326.

927 com caracteres de controle, como tabulações. As datas usavam o mesmo formato e os nulos eram valores nulos reais, sem ocorrências da string “NULL”.

Nós olhamos as quatro colunas de texto livre da Tabela 1 usando principalmente expressões regulares em Python. Encontramos padrões de telefone em 4.371 tuplas, e-mail em 162, CPF em 39 e RG em 11. Parte dos e-mails era da prefeitura, e as correspondências não garantem a identificação de cidadãos. Também encontramos um caso de cartão de crédito e um de conta bancária, validados na atividade.

Na base de 146.094 registros considerada nessa verificação, apenas 2.451 tinham data de nascimento nula: cerca de 98,3% continham esse dado. Apenas uma tupla não tinha LOGRADOURO_ASS, e 121.414, aproximadamente 83%, apresentavam logradouro e número válido do imóvel.

Os nomes apresentaram as maiores dificuldades. Testamos expressões regulares e a biblioteca spaCy, mas encontramos muitos falsos positivos, inclusive nomes de ruas. A busca em SQL retornou 2.331 resultados com precisão insatisfatória. Propusemos mascarar informações pessoais, remover ou generalizar a data de nascimento e ocultar números dos imóveis. Para nomes, ocultar palavras após pronomes de tratamento foi uma possibilidade, mas não garante anonimização completa.

4. Inclusão de coordenadas geográficas

Adicionamos a coluna geom, do tipo POINT, com SRID 4326. Usamos a tabela alvara_enderecos para associar logradouros e números dos imóveis às coordenadas, criamos um índice GiST e visualizamos os resultados no QGIS. A atualização informou 48.709 linhas afetadas, mas a consulta final encontrou 31.605 tuplas com geometria não nula, cerca de 22,2% das 142.221 tuplas. Os relatórios não explicam a diferença entre linhas atualizadas e coordenadas preenchidas.

5. Análise exploratória